

# Análisis de artículo para Aprendizaje No Supervisado

## Autor: Emilio Jesús Hernández Salas

Joint Unsupervised Learning of Deep Representations and Image Clusters

### 1. Problema abordado

Yang et al (2016) proponen un marco de aprendizaje E2E simple pero eficaz para aprender conjuntamente representaciones profundas y clústeres de imágenes a partir de un conjunto de imágenes sin etiquetar

### 2. Método propuesto y sus contribuciones al estado del arte

Este trabajo propone un marco recurrente llamado JULE para el aprendizaje conjunto no supervisado de representaciones profundas y clusters de imágenes, donde el clustering sobre imágenes y el aprendizaje de representaciones se integran en un único modelo para obtener representaciones más potentes y clusters de imágenes más precisos. El método propuesto supera en muchos aspectos a los encontrados en la literatura sobre clustering de imágenes y, adicionalmente, las representaciones aprendidas se generalizan bien a otras tareas.

Se formula el aprendizaje conjunto en un marco recurrente, donde las operaciones de fusión de la agrupación aglomerativa se expresan como un forward propagation, y el aprendizaje de representación de CNN como un backward propagation. Se deriva una única función de pérdida para guiar el agrupamiento aglomerativo y el aprendizaje de representaciones profundas, lo que hace que la optimización sobre las dos tareas sea fluida.

Los resultados experimentales muestran que el marco propuesto supera a los métodos anteriores de agrupamiento de imágenes y aprende representaciones profundas que pueden transferirse a otras tareas y conjuntos de datos. Han propuesto un enfoque para aprender conjuntamente representaciones profundas y clusters de imágenes. Son testigos de una explosión del contenido visual.

La idea de la función de pérdidas a optimizar es, dado un número  $n_s$  de imágenes tal que  $I = I_1, \dots, I_{n_s}$ , la función objetivo global para el aprendizaje de representaciones y clusters de imágenes puede escribirse como: (1).

$$\operatorname{argmin}_{y, \theta} \mathcal{L}(y, \theta | I) \quad (1)$$

Siendo  $\mathcal{L}(\cdot)$  la función de pérdidas,  $y$  los id de los clusters y  $\theta$  los parámetros para el problema de representación, se tiene que el problema de clustering, dadas unos parámetros para la representación se resuelve optimizando (2a). Mientras que el problema de representación se resuelve optimizando (2b) dados unos clusters determinados.

$$\operatorname{argmin}_y \mathcal{L}(y | I, \theta) \quad (2a)$$

$$\operatorname{argmin}_{\theta} \mathcal{L}(\theta | I, y) \quad (2b)$$

Yang et al recomiendan que el texto sugiera la introducción de una función de pérdidas que permita confinar la estructura dentro de los clusters, pero esto se deja como trabajo futuro debido al espacio limitado.

A modo de resumen, una de las grandes mejoras que supone respecto al resto de los métodos de la literatura es la posibilidad de aprovechar las representaciones aprendidas. Debido a la generalización de dichas representaciones, se puede realizar transfer learning para diversas tareas. En el artículo se comenta como se ha podido extrapolar el conocimiento de la red sobre un dataset de objetos sobre otro de dígitos escritos a mano.

### 3. Posibles mejoras

#### 3.1. Uso de clustering probabilístico

Como hemos visto en clase, uno de los algoritmos de clustering que mejor se adaptan a estas tareas de Deep Clustering es el probabilístico. Se podría hacer el estudio de cómo se comporta el mismo modelo recurrente pero con GMM.

#### 3.2. Incluir la comparación con VAEs

Se podría incluir la comparación con VAE, no sólo para comparar la obtención del espacio latente, sino para comparar la performance del VAE + Clustering Jerárquico como método de Deep Clustering.